Estatística: Conceitos e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA wyden

Disciplina: Simulação de Sistemas Computacionais

Professor: Ruy Barbosa Figueiredo Junior

I. Introdução

A simulação de sistemas digitais depende fundamentalmente de conceitos estatísticos e probabilísticos para modelar comportamentos incertos, como tráfego em redes, tempos de resposta de servidores e falhas em sistemas.

A estatística pode ser aplicada diretamente na simulação de sistemas digitais, desde a geração de dados até a análise e validação dos resultados.

Sistemas reais são cheios de variáveis imprevisíveis — tempo de resposta, falhas, tráfego de rede. A estatística permite representar essas incertezas com distribuições de probabilidade (como normal, exponencial, binomial), tornando a simulação mais realista.

Nem sempre temos dados reais suficientes. A estatística permite gerar dados simulados com base em parâmetros conhecidos, usando técnicas como amostragem ou geração de números pseudoaleatórios.

Este material apresenta uma base teórica e prática para aplicar estatística na simulação, utilizando Python para exemplos e visualizações.

II. Estatística

Estatística é uma ciência — mais especificamente, uma ciência matemática aplicada que estuda a coleta, análise, interpretação e apresentação de dados. Ela é fundamental para a tomada de decisões em condições de incerteza e é amplamente aplicada em praticamente todas as áreas do conhecimento.

A Estatística divide-se em várias áreas interligadas, cada uma com foco específico, para a simulação de sistemas computacionais, utilizamos principalmente estas áreas da estatística:

2.1 Estatística Descritiva

Objetivo: Resumir, organizar e visualizar dados.

2.1.1 Medidas de Dispersão

São valores que representam o centro ou o ponto de equilíbrio de um conjunto de dados. Elas resumem a informação de uma distribuição, indicando onde os dados tendem a se concentrar.

Principais Medidas e Suas Funções:

<u>Média Aritmética</u>: Soma de todos os valores dividida pelo número de observações.

- Fornece um valor "típico" do conjunto.
- Usada em cálculos estatísticos mais complexos (exemplo: variância, regressão).
- Melhor uso: Quando os dados são simétricos e sem valores extremos.

Mediana: Valor que divide os dados ordenados em duas partes iguais.

- Representar o centro em distribuições assimétricas.
- Não é afetada por valores extremos (outliers).
- Melhor uso: Para dados com distribuição não normal ou com outliers.

Moda: Valor que ocorre com maior frequência no conjunto.

- Identificar o valor mais comum.
- Útil para dados categóricos (exemplo: cor preferida, marca mais popular).
- Melhor uso: Para variáveis qualitativas ou para detectar picos em distribuições.

Exemplos:

Dado um conjunto de dados que representa as idades de um grupo de pessoas, pede-se: Calcule a média aritmética, a mediana e a moda.

```
idades = [18, 22, 25, 25, 30, 32, 35, 40, 45, 80]
```

Média Aritmética

Soma de todos os valores dividida pelo número de elementos:

```
Média = (18 + 22 + 25 + 25 + 30 + 32 + 35 + 40 + 45 + 80) / 10
Média = 352 / 10 = 35,2 anos
```

Mediana

Valor central quando os dados estão ordenados:

```
Dados ordenados: 18, 22, 25, 25, 30, 32, 35, 40, 45, 80
Como temos 10 elementos (número par), a mediana é a média dos dois valores centrais:
Mediana = (30 + 32) / 2 = 31 anos
```

Moda

Valor que aparece com maior frequência:

```
Moda = 25 anos (aparece duas vezes)
```

Limitações e Cuidados

- Média: Sensível a valores extremos.
- Mediana: Ignora a magnitude de valores extremos.
- Moda: Pode não ser única ou representativa se houver múltiplos picos.

2.1.2 Medidas de Dispersão

As medidas de dispersão são indicadores estatísticos que quantificam o quanto os dados de um conjunto variam entre si. Elas complementam as medidas de tendência central (como média e mediana), mostrando se os valores estão concentrados ou espalhados.

Servem para:

- Entender a Variabilidade dos Dados:
  Revelam se os valores são homogêneos (pouca variação) ou heterogêneos (muita variação).
  Exemplo: Em um servidor web, tempos de resposta muito variáveis podem indicar instabilidade.

- Comparar Conjuntos de Dados:
  Permitem comparar a dispersão de diferentes amostras ou populações.
  Exemplo: Comparar a consistência do tempo de resposta de dois servidores.

- Tomar Decisões com Base na Incerteza:
  Em simulação de sistemas, ajudam a avaliar riscos e prever comportamentos extremos.
  Exemplo: Planejar capacidade de hardware para lidar com picos de tráfego.

- Validar Modelos Estatísticos:
  Distribuições com alta dispersão podem exigir ajustes nos modelos de simulação.

Principais medidas de dispersão:

Variância: Mede a média dos quadrados das diferenças entre cada valor e a média.
Fórmula (amostral):

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Interpretação: Quanto maior a variância, mais dispersos os dados.

Desvio Padrão " σ ": É a raiz quadrada da variância.
- Vantagem: Está na mesma unidade dos dados original.

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Em Python

```python
import numpy as np
dados = np.array([10, 12, 9, 11, 15])
desvio_padrao = np.std(dados, ddof=1)  # ddof=1 para amostra
print(f"Desvio Padrão: {desvio_padrao:.2f}")
```

```
Desvio Padrão: 2.30
```

Amplitude: Diferença entre o maior e o menor valor do conjunto.
- Limitação: Sensível a valores extremos (outliers).
Em Python: Notas de uma turma em uma prova
notas = [68, 72, 75, 78, 80, 82, 85, 88, 90, 95]

Cálculo da amplitude:

```python
import numpy as np

notas = [68, 72, 75, 78, 80, 82, 85, 88, 90, 95]

valor_maximo = np.max(notas)  # 95
valor_minimo = np.min(notas)  # 68
amplitude = valor_maximo - valor_minimo  # 27

print(f"Notas: {notas}")
print(f"Valor máximo: {valor_maximo}")
print(f"Valor mínimo: {valor_minimo}")
print(f"Amplitude: {amplitude} pontos")
```

```
Notas: [68, 72, 75, 78, 80, 82, 85, 88, 90, 95]
Valor máximo: 95
Valor mínimo: 68
Amplitude: 27 pontos
```

Limitações:

```python
# Adicionando um outlier (aluno que faltou e tirou 0)
notas_com_outlier = [0, 72, 75, 78, 80, 82, 85, 88, 90, 95]

amplitude_outlier = np.max(notas_com_outlier) - np.min(notas_com_outlier)
print(f"Amplitude com outlier: {amplitude_outlier} pontos")  # 95 pontos!
```

```
Amplitude com outlier: 95 pontos
```

Problema: A amplitude aumentou de 27 para 95 pontos devido a um único valor extremo, distorcendo completamente a percepção da dispersão real dos dados.

<u>Coeficiente de Variação (CV)</u>: Relaciona o desvio padrão à média (em porcentagem).
- Fórmula:

$$CV = \frac{s}{\bar{x}} \times 100\%$$

- Uso: Comparar dispersão entre conjuntos com unidades ou médias diferentes. É a ferramenta ideal quando você precisa responder: "Esta variação é grande em relação ao que estamos medindo?"

Em Python

```python
import numpy as np

# Dados de exemplo
dados = [10, 12, 14, 15, 18, 21, 22]

# Calcular média e desvio padrão amostral
media = np.mean(dados)
desvio_padrao = np.std(dados, ddof=1)  # ddof=1 para desvio padrão amostral

# Coeficiente de variação
cv = (desvio_padrao / media) * 100

print(f"Média: {media:.2f}")
print(f"Desvio padrão: {desvio_padrao:.2f}")
print(f"Coeficiente de variação: {cv:.2f}%")
```

```
Média: 16.00
Desvio padrão: 4.51
Coeficiente de variação: 28.18%
```

Isso significa que o desvio padrão é aproximadamente 28,88% da média, indicando uma variabilidade relativa moderada.

Observação: O coeficiente de variação é mais útil quando os dados são sempre positivos (média > 0) e quando a distribuição é aproximadamente normal ou simétrica.

Estatística: Conceitos e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA
wyden

```python
import numpy as np

# Dados de exemplo: salários de duas empresas (em R$)
empresa_A = [2500, 2700, 3000, 3200, 3500]  # Menor variação
empresa_B = [1500, 2500, 3500, 4500, 5500]  # Maior variação

def coeficiente_variacao(dados):
    media = np.mean(dados)
    desvio_padrao = np.std(dados, ddof=1)  # ddof=1 para amostra
    cv = (desvio_padrao / media) * 100
    return cv, media, desvio_padrao

# Cálculo para cada empresa
cv_A, media_A, dp_A = coeficiente_variacao(empresa_A)
cv_B, media_B, dp_B = coeficiente_variacao(empresa_B)

print("=== EMPRESA A ===")
print(f"Média: R$ {media_A:.2f}")
print(f"Desvio padrão: R$ {dp_A:.2f}")
print(f"Coeficiente de variação: {cv_A:.2f}%")

print("\n=== EMPRESA B ===")
print(f"Média: R$ {media_B:.2f}")
print(f"Desvio padrão: R$ {dp_B:.2f}")
print(f"Coeficiente de variação: {cv_B:.2f}%")

# Interpretação
print("\n=== INTERPRETAÇÃO ===")
print(f"A Empresa B tem {cv_B/cv_A:.1f}x mais variação relativa nos salários")
```

```
=== EMPRESA A ===
Média: R$ 2980.00
Desvio padrão: R$ 396.23
Coeficiente de variação: 13.30%

=== EMPRESA B ===
Média: R$ 3500.00
Desvio padrão: R$ 1581.14
Coeficiente de variação: 45.18%

=== INTERPRETAÇÃO ===
A Empresa B tem 3.4x mais variação relativa nos salários
```

Exemplo Prático em Simulação de Sistemas:

Suponha que você está analisando o tempo de resposta de um servidor (em milissegundos):
- Amostra 1: [100, 105, 98, 102, 101]
- Amostra 2: [80, 120, 90, 110, 100]

Apresente os códigos para o cálculo da média aritmética, variância, desvio padrão e coeficiente de variação. Faça a análise dos resultados e indique qual amostra representa um sistema mais estável e qual amostra representa um comportamento imprevisível do sistema?

```python
import numpy as np

# Dados das amostras
amostra1 = np.array([100, 105, 98, 102, 101])
amostra2 = np.array([80, 120, 90, 110, 100])

# Função para calcular estatísticas
def estatisticas(dados):
    media = np.mean(dados)
    variancia = np.var(dados, ddof=1)  # ddof=1 para amostra
    desvio = np.std(dados, ddof=1)
    coef_var = (desvio / media) * 100
    return media, variancia, desvio, coef_var

# Calculando para ambas as amostras
m1, v1, d1, cv1 = estatisticas(amostra1)
m2, v2, d2, cv2 = estatisticas(amostra2)

# Exibindo os resultados
print("📊 Amostra 1:")
print(f"Média: {m1:.2f} ms")
print(f"Variância: {v1:.2f}")
print(f"Desvio Padrão: {d1:.2f}")
print(f"Coeficiente de Variação: {cv1:.2f}%\n")

print("📊 Amostra 2:")
print(f"Média: {m2:.2f} ms")
print(f"Variância: {v2:.2f}")
print(f"Desvio Padrão: {d2:.2f}")
print(f"Coeficiente de Variação: {cv2:.2f}%")
```

```
📊 Amostra 1:
Média: 101.20 ms
Variância: 6.70
Desvio Padrão: 2.59
Coeficiente de Variação: 2.56%

📊 Amostra 2:
Média: 100.00 ms
Variância: 250.00
Desvio Padrão: 15.81
Coeficiente de Variação: 15.81%
```

Gráfico de Visualização

```python
[7] import matplotlib.pyplot as plt

    dados1 = [100, 105, 98, 102, 101]
    dados2 = [80, 120, 90, 110, 100]

    plt.boxplot([dados1, dados2], labels=["Amostra 1", "Amostra 2"])
    plt.title("Dispersão do Tempo de Resposta do Servidor")
    plt.ylabel("Milissegundos")
    plt.show()
```

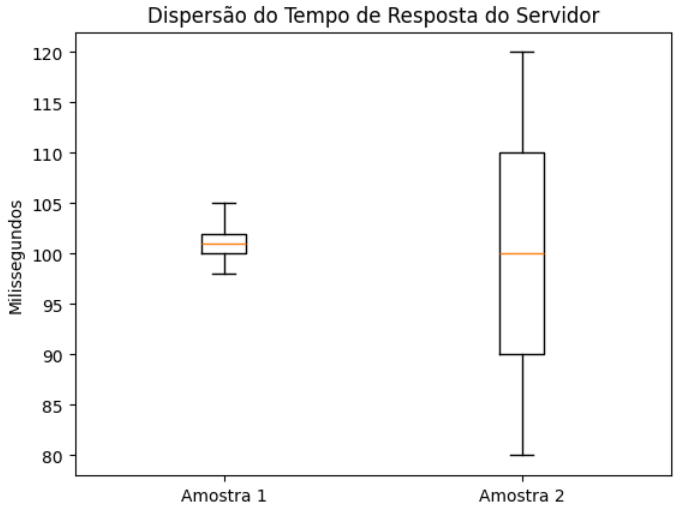

Interpretação do Boxplot:
- As caixas mostram a dispersão (quartis).
- Amostra 2 tem maior amplitude e outliers.

Quartis são como “marcadores de posição” que dividem um conjunto de dados ordenados em quatro partes iguais. Eles ajudam a entender como os dados estão distribuídos — especialmente se há concentração, dispersão ou outliers.

Imagine que você tem uma fila de números ordenados. Os quartis dividem essa fila em quatro partes com 25% dos dados em cada uma:

- Q1 (primeiro quartil): marca o ponto abaixo do qual estão os 25% menores valores.
- Q2 (segundo quartil): é a mediana, ou seja, o valor central (50% dos dados abaixo).
- Q3 (terceiro quartil): marca o ponto abaixo do qual estão 75% dos dados.

Exemplo prático

Suponha os dados:
[10, 12, 15, 18, 20, 22, 25, 28]
Q1 = 13.5 → 25% dos dados estão abaixo disso
- Q2 = 19 → é a mediana
- Q3 = 23.5 → 75% dos dados estão abaixo disso

```
import numpy as np

dados = np.array([10, 12, 15, 18, 20, 22, 25, 28])
q1 = np.percentile(dados, 25)
q2 = np.percentile(dados, 50)
q3 = np.percentile(dados, 75)

print(f"Q1: {q1}")
print(f"Q2 (mediana): {q2}")
print(f"Q3: {q3}")
```

```
Q1: 14.25
Q2 (mediana): 19.0
Q3: 22.75
```

Estatística: Conceitos e Aplicação à Simulação de Sistemas Digitais

Importância dos gráficos na simulação de sistemas computacionais:
- Identificar distribuição dos dados.
- Detectar outliers (valores muito fora da curva)
- Construir boxplots (gráficos que resumem os dados visualmente)
- Análise da precisão de modelos: Distribuições com alta dispersão (ex: Exponencial) exigem mais amostras para simulações confiáveis.
- Otimização de Recursos: Identificar se um sistema tem variação excessiva ajuda a priorizar melhorias.
- Análise de Risco: Medidas como desvio padrão preveem cenários de pico e falhas.

Limitações e Cuidados

- Média: Sensível a valores extremos.

- Mediana: Ignora a magnitude de valores extremos.

- Moda: Pode não ser única ou representativa se houver múltiplos picos.

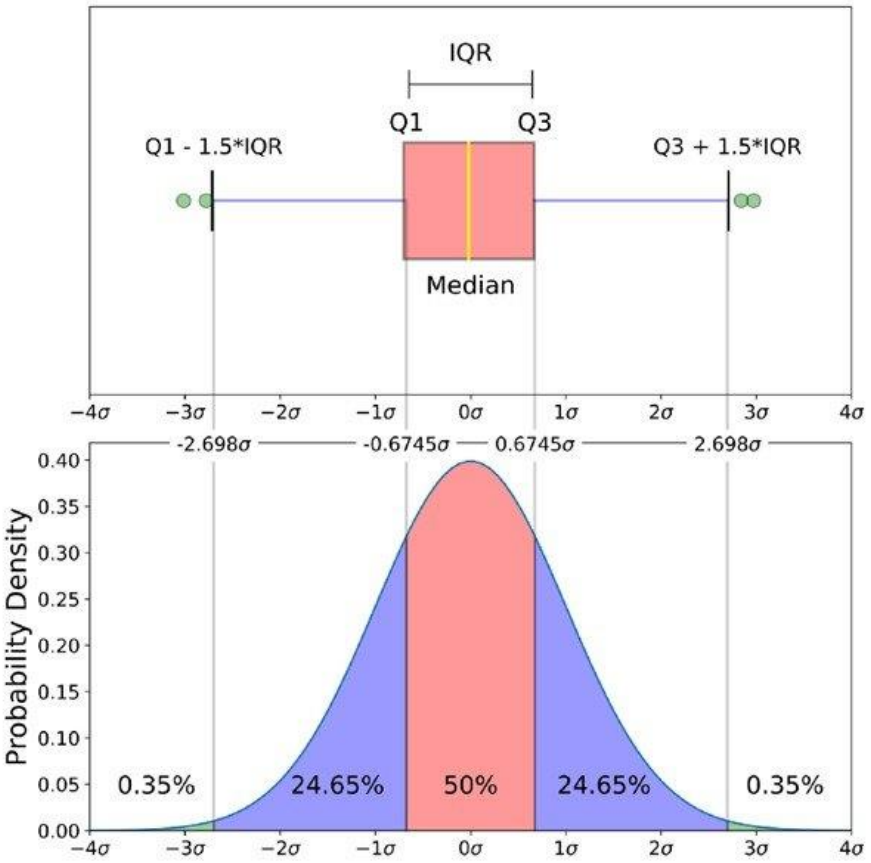

2.2 Estatística Inferencial

A estatística inferencial é o ramo da estatística que permite tirar conclusões sobre uma população com base na análise de amostras dessa população. Em vez de apenas descrever os dados (como faz a estatística descritiva), ela busca inferir padrões, testar hipóteses e estimar parâmetros com base em modelos probabilísticos.

Ela vai além da simples descrição dos dados para fazer generalizações e previsões.

Na simulação de sistemas — como redes de computadores, fábricas, sistemas logísticos ou financeiros — a estatística inferencial é essencial para garantir que os resultados obtidos sejam confiáveis e generalizáveis.

🧩 Aplicação	📊 Como a Estatística Inferencial contribui
Seleção de variáveis de entrada	Ajuda a identificar quais variáveis realmente influenciam o sistema, por meio de testes e análise de sensibilidade [1]
Modelagem de incertezas	Representa variáveis aleatórias e distribuições probabilísticas para simular cenários realistas [1]
Validação de modelos	Compara os resultados simulados com dados reais para verificar se o modelo é estatisticamente confiável
Análise de desempenho	Permite estimar métricas como tempo médio de resposta, taxa de erro, etc., com margem de erro controlada
Tomada de decisão	Gera evidências quantitativas para escolher entre diferentes alternativas simuladas

2.2.1. Conceitos Fundamentais

<u>População X Amostra</u>

População:

- Refere-se ao conjunto total de elementos que possuem uma característica comum e que são objeto de estudo.
- Pode ser composta por pessoas, objetos, eventos, ou qualquer unidade de análise.

Exemplos:

- Todos os eleitores de Belo Horizonte.

- Todas as escolas particulares de Minas Gerais.

- Todos os carros fabricados por uma montadora em 2024.

Estatística: Conceitos e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA wyden

Amostra:

- É um subconjunto da população, selecionado para representar o todo.
- Usada quando estudar a população inteira seria inviável por tempo, custo ou logística.
- Deve ser escolhida de forma que represente fielmente a população para garantir validade estatística.

Exemplos:

- 500 eleitores de BH entrevistados numa pesquisa eleitoral.

- 30 escolas particulares analisadas para avaliar desempenho educacional.

Conceito	Definição	Exemplo
População	Total de elementos do estudo	Todos os alunos de uma universidade
Amostra	Parte representativa da população	200 alunos escolhidos aleatoriamente

A ideia é que, ao estudar a amostra, você possa inferir conclusões sobre a população com um certo grau de confiança estatística.

<u>Parâmetros e Estatísticas</u>

- Parâmetro: valor que descreve uma característica da população (exemplo: média populacional).

- Estatística: valor calculado a partir da amostra (exemplo: média amostral).

<u>Estimativas</u>

- Estimativa pontual: um único valor que estima um parâmetro (exemplo: média da amostra como estimativa da média populacional).

- Intervalo de confiança: faixa de valores que provavelmente contém o parâmetro populacional, com um certo nível de confiança (exemplo: 95%).

<u>Testes de Hipóteses</u>

- Método para verificar se uma afirmação sobre a população é plausível com base nos dados da amostra.

- Envolve:

  - Hipótese nula (H_0): afirmação inicial (exemplo: “não há diferença”).

  - Hipótese alternativa (H_1): o que queremos provar (exemplo: “há diferença”).

  - Valor-p: probabilidade de obter os resultados observados se H_0 for verdadeira.

  - Nível de significância (α): geralmente 0,05; se o valor-p for menor que α, rejeitamos H_0.

Estatística: Conceitos e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA wyden

Erros Estatísticos

- Erro Tipo I (α): rejeitar H_0 quando ela é verdadeira.

- Erro Tipo II (β): não rejeitar H_0 quando ela é falsa.

Distribuições de Probabilidade

- Modelos matemáticos que descrevem como os dados se comportam.

- Exemplo clássico: distribuição normal, usada em muitos testes estatísticos.

Parâmetro x Estatística:

Tipo de Média	Símbolo	Significado
Média populacional	μ	Letra grega "mi", representa a média da **população** [1]
Média amostral	$\bar{x}$	Lê-se "x barra", representa a média da **amostra** [2]

- Parâmetro: Média descritiva da população - μ (mi) é usado quando estamos lidando com parâmetros populacionais, ou seja, quando queremos descrever toda a população.

- Estatística $\bar{x}$ (x barra): Medida descritiva da amostra - é usado quando calculamos a média com base em uma amostra retirada da população.

Intervalo de Confiança

Um intervalo de confiança é uma faixa de valores que, com determinada probabilidade (chamada de nível de confiança), contém o verdadeiro valor do parâmetro populacional.

Por exemplo:

Se você calcular um intervalo de confiança de 95% para a média de altura de uma população, isso significa que há 95% de confiança de que esse intervalo inclui a verdadeira média populacional.

Exemplo Prático:

Suponha que você tenha uma amostra de 10 pessoas com média de altura de 171,4 cm e um intervalo de confiança de 95% calculado como (168,8 cm, 174,0 cm). Isso quer dizer:

> Estamos 95% confiantes de que a média real da população está entre 168,8 cm e 174,0 cm.

Interpretação Correta:

> "Estamos 95% confiantes de que o intervalo calculado contém o verdadeiro valor."

Não se deve dizer que "há 95% de chance de que o valor esteja dentro do intervalo", porque o valor populacional é fixo — o que varia é o intervalo, dependendo da amostra.

Estatística: Conceitos e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA wyden

Aplicações em Python

Exemplo 01:

```python
# Exemplo: Estimação da média populacional
import numpy as np
from scipy import stats

# Amostra de alturas (cm)
alturas_amostra = [165, 170, 172, 168, 175, 169, 171, 174, 167, 173]

# Intervalo de confiança 95% para a média populacional
media_amostral = np.mean(alturas_amostra)
erro_padrao = stats.sem(alturas_amostra)
intervalo_confianca = stats.t.interval(0.95, len(alturas_amostra)-1,
                                       loc=media_amostral, scale=erro_padrao)

print(f"Média amostral: {media_amostral:.2f} cm")
print(f"Intervalo de 95% confiança: {intervalo_confianca}")
```

```
Média amostral: 170.40 cm
Intervalo de 95% confiança: (np.float64(168.10787918506955), np.float64(172.69212081493046))
```

Vamos analisar o algoritmo:

1. Define uma amostra de alturas (em cm).

2. Calcula a média amostral com np.mean().

3. Calcula o erro padrão da média com stats.sem() — essencial para medir a variabilidade da média.

4. Constrói um intervalo de confiança de 95% usando a distribuição t de Student, já que o tamanho da amostra é pequeno (n < 30).

Ou seja, com 95% de confiança, podemos afirmar que a média populacional está entre 168,10 cm e 172,69 cm, com base nessa amostra.

Por que usar a distribuição t?

Porque:

- A amostra é pequena.

- A variância populacional é desconhecida.

- A distribuição t é mais conservadora, ajustando-se ao tamanho da amostra.

Exemplo 02:

```python
# Exemplo: Teste t para comparar duas médias
grupo_A = [68, 72, 75, 78, 80]  # Notas do método tradicional
grupo_B = [75, 78, 82, 85, 88]  # Notas do novo método

# Teste t independente
t_stat, p_valor = stats.ttest_ind(grupo_A, grupo_B)

print(f"Estatística t: {t_stat:.3f}")
print(f"Valor-p: {p_valor:.3f}")

if p_valor < 0.05:
    print("Diferença estatisticamente significativa (α=5%)")
else:
    print("Não há evidência de diferença significativa")
```

```
Estatística t: -2.211
Valor-p: 0.058
Não há evidência de diferença significativa
```

O algoritmo compara as médias dos grupos (método tradicional) e (novo método) para verificar se o novo método produz resultados significativamente diferentes.

Passo a Passo do Algoritmo

1. Definição das amostras

```python
grupo_A = [68, 72, 75, 78, 80]
grupo_B = [75, 78, 82, 85, 88]
```

Cada lista representa as notas de alunos submetidos a diferentes métodos de ensino.

2. Aplicação do teste t para amostras independentes

```python
t_stat, p_valor = stats.ttest_ind(grupo_A, grupo_B)
```

- stats.ttest_ind() realiza o teste t de Student para verificar se as médias dos dois grupos são estatisticamente diferentes.
- Retorna:

  - t_stat: valor da estatística t.

  - p_valor: probabilidade de observar essa diferença se H_0 (hipótese nula) for verdadeira.

3. Exibição dos resultados

```python
print(f"Estatística t: {t_stat:.3f}")
print(f"Valor-p: {p_valor:.3f}")
```

- Mostra os valores calculados com 3 casas decimais.

4. Interpretação estatística

```
if p_valor < 0.05:
    print("Diferença estatisticamente significativa (α=5%)")
else:
    print("Não há evidência de diferença significativa")
```

Nível de significância (α): 0,05 (ou 5%).

- Se o valor-p for menor que 0,05, rejeitamos a hipótese nula e concluímos que há diferença significativa entre os métodos.

✅ Como o valor-p (0.058) é maio que 0.05, não há evidência estatística de que os métodos produzem médias diferentes.