Teoria das Filas e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA wyden

Disciplina: Simulação de Sistemas Computacionais

Professor: Ruy Barbosa Figueiredo Junior

1. Introdução à Teoria das Filas

A Teoria das Filas é um ramo da pesquisa operacional e da probabilidade que estuda matematicamente o comportamento de linhas de espera. Desenvolvida inicialmente por A. K. Erlang no contexto de sistemas telefônicos, a teoria busca dimensionar recursos de forma a equilibrar demanda e capacidade, minimizando tempos de espera e evitando congestionamentos

1.1. Aplicações:

A teoria das filas é uma ferramenta matemática poderosa que serve para analisar e otimizar sistemas de espera — desde filas em supermercados até servidores em redes de computadores. Ela ajuda a entender como os recursos são utilizados e como minimizar o tempo de espera dos "clientes", que podem ser pessoas, dados, veículos ou qualquer entidade que aguarda por um serviço.
Principais objetivos da teoria das filas:

- Reduzir o tempo de espera
- Evitar gargalos e sobrecarga nos sistemas
- Melhorar a eficiência dos serviços
- Dimensionar corretamente recursos como atendentes, máquinas ou servidores

Onde é utilizada:

- **Sistemas Computacionais:** Escalonamento de processos, redes de computadores, servidores web, bancos de dados.
- **Telecomunicações:** Controle de tráfego de pacotes em roteadores.
- **Logística e Serviços:** Pedágios, aeroportos, supermercados, hospitais.
- **Manufatura:** Linhas de produção e controle de manutenção.

Utilização na Computação:

- Gerenciamento de Processos em Sistemas Operacionais: O sistema operacional usa filas para agendar processos que aguardam tempo de CPU.

Modelos como M/M/1 ajudam a prever o tempo médio de espera e a utilização do processador.
Exemplo: o escalonador de tarefas do Linux pode ser modelado como uma fila com múltiplos servidores (núcleos de CPU).

- Servidores Web e Balanceamento de Carga: Quando múltiplos usuários acessam um site, os pedidos são enfileirados para serem processados por servidores.

A teoria das filas ajuda a decidir quantos servidores são necessários para manter o tempo de resposta baixo.
Exemplo: servidores de aplicações como Nginx ou Apache usam filas para gerenciar requisições simultâneas.

- Redes de Computadores: Pacotes de dados são enfileirados em roteadores e switches antes de serem encaminhados.

Modelos de filas ajudam a prever congestionamento de rede e a melhorar protocolos como TCP/IP.
Exemplo: filas FIFO (First-In, First-Out) são comuns em buffers de rede.

- Inteligência Artificial e *Machine Learning*: Em sistemas distribuídos de treinamento de modelos, tarefas são enfileiradas para serem processadas por GPUs.

A teoria das filas ajuda a otimizar o uso de recursos computacionais em clusters.

- Sistemas de Banco de Dados: Consultas são enfileiradas para acesso ao banco, especialmente em sistemas com alta concorrência.

A modelagem de filas permite prever tempo de resposta e taxa de *throughput*.

- Simulação e Modelagem de Sistemas: Ferramentas como SimPy (Python) ou Arena usam teoria das filas para simular sistemas complexos.

Exemplo: simular o comportamento de uma fila de impressão em uma rede corporativa.

1.2. Elementos de um Sistema de Filas:

Um sistema de filas é composto por:

1. **População de Clientes:** Fonte de entidades que demandam serviço (finita ou infinita).

2. **Processo de Chegada:** Modelado por uma distribuição de probabilidade para o tempo entre chegadas (exemplo: exponencial).

3. **Processo de Serviço:**

- **Fila (*Buffer*):** Local onde os clientes aguardam pelo serviço. Sua capacidade pode ser finita ou infinita.
  - Mecanismo de Disciplina da Fila: Regra que define a ordem de atendimento. A mais comum é FIFO (*First-In, First-Out*/Primeiro a Entrar, Primeiro a Sair). Outras incluem LIFO, Prioridades, etc.

  - Servidor(s): Entidade(s) que realiza(m) o serviço. O tempo gasto para atender um cliente é modelado por uma distribuição de probabilidade para o tempo de serviço (exemplo: Distribuição Exponencial).

- **Disciplina da Fila:** Regra de atendimento (exemplo: FIFO, LIFO, prioridades).

- **Servidor(es):** Recurso que realiza o serviço, com tempo de serviço modelado probabilisticamente.

Medidas de Desempenho:

- ρ: Taxa de utilização do(s) servidor(es).
- L: Número médio de clientes no sistema.
- Lq: Número médio de clientes na fila.
- W: Tempo médio no sistema.
- Wq: Tempo médio de espera na fila.

2. Notação de Kendall

A notação de Kendall é uma forma padronizada e compacta de descrever modelos de filas na teoria das filas. Ela foi proposta por David G. Kendall em 1953 e é amplamente usada para representar sistemas de espera em diversas áreas, como computação, engenharia, logística e saúde.

Estrutura da Notação:

Cada letra ou símbolo representa uma característica do sistema de filas:

Símbolo	Significado	Descrição
A	Processo de Chegada	Distribuição dos tempos entre chegadas (exemplo: M para exponencial, D para determinístico e G para geral)
B	Processo de serviço	Distribuição dos tempos de atendimento (Mesmas opções de A)
c	Número de servidores	Quantos servidores atendem simultaneamente
k	Capacidade de sistema	Número máximo de clientes no sistema (fila + serviço)
m	Tamanho da população	Número total de clientes possíveis (Exemplo: usuários de um determinado sistema)
z	Escalonamento (disciplina) da fila	Ordem de atendimento (Exemplo: FIFO, LIFO, prioridade)

A (Processo de Chegadas): Distribuição dos tempos entre chegadas.

- M (*Markovian*): Distribuição Exponencial (única distribuição contínua sem memória).
- D (*Deterministic*): Tempos constantes entre chegadas.
- G (*General*): Qualquer distribuição geral (exemplo: Normal, Uniforme).
- Ek (*Erlang-k*): Distribuição Erlang de estágio k.

B (Processo de Serviço): Distribuição dos tempos de serviço.
M, D, G, Ek (as mesmas definições de `A` se aplicam).

c (Número de Servidores): Número de servidores paralelos e idênticos no sistema (exemplo: 1, 2, 3, ... k).

K (Capacidade do Sistema - Opcional): Número máximo de clientes permitidos no sistema (fila + serviço). Se omitido, assume-se capacidade infinita.

m (Tamanho da População - Opcional): Tamanho da população de clientes. Se omitido, assume-se população infinita.

Z (Disciplina da Fila - Opcional): Regra de atendimento (exemplo: FIFO, LIFO, Prioridade). Se omitida, assume-se FIFO.

Exemplos:

- M/M/1: Chegadas Markovianas (Exponencial), Serviços Markovianos (Exponencial), 1 servidor, capacidade infinita, população infinita, disciplina FIFO.
- M/D/3/10: Chegadas Markovianas, Serviços Determinísticos (constantes), 3 servidores, capacidade máxima do sistema é 10 clientes.
- M/G/4: Chegadas Markovianas, Serviços com distribuição Geral, 4 servidores.

3. Análise de Sistemas de Filas Simples (M/M/1 e M/M/k)

Para a análise, assumimos população infinita, disciplina FIFO e capacidade infinita, a menos que especificado o contrário.

3.1. Sistema M/M/1

É o modelo mais simples e fundamental.
Premissas:

- ✓ Chegadas seguem um processo de Poisson com taxa λ
- ✓ Tempos de serviço são exponenciais com taxa μ
- ✓ k servidores idênticos
- ✓ Fila única, capacidade infinita
- ✓ Ordem de atendimento: FIFO
- ✓ Condição de estabilidade: $\rho = (\lambda/k\mu) < 1$

- Taxa de chegada(λ): Número médio de chegadas por unidade de tempo.
- Taxa de serviço (μ): Número médio de clientes que um servidor pode atender por unidade de tempo.
- Condição de Estabilidade: A taxa de chegada deve ser menor que a taxa de serviço ($\lambda < \mu$). Caso contrário, a fila crescerá indefinidamente.
- À medida que ρ se aproxima de 1, o sistema entra em colapso: filas crescem indefinidamente e tempos de espera explodem.

Medidas de Desempenho (Fórmulas):

Métrica	Fórmula	Interpretação
1. Fator de Utilização do sistema	$\rho = \frac{\lambda}{\mu}$	Proporção do tempo que o servidor está ocupado. Deve ser menor que 1 para evitar sobrecarga.
2. Número médio no sistema	$L = \frac{\lambda}{\mu - \lambda}$	Quantidade média de clientes ou tarefas presentes no sistema, incluindo os que estão sendo atendidos e os que estão esperando na fila.
3. Número médio na fila	$L_q = \frac{\lambda^2}{\mu(\mu - \lambda)}$	Quantidade média de clientes que estão esperando para serem atendidos — ou seja, na fila, excluindo o cliente que está sendo atendido.
4. Tempo médio no sistema	$W = \frac{1}{\mu - \lambda}$	Tempo médio que um cliente passa no sistema, desde o momento em que chega até o momento em que sai, incluindo: • o tempo de espera na fila • o tempo de atendimento
5. Tempo médio na fila	$W_q = \frac{\lambda}{\mu(\mu - \lambda)}$	Tempo médio que um cliente espera na fila antes de começar a ser atendido. Esse valor não inclui o tempo de atendimento, apenas o tempo de espera.

Fórmula de Little (válida para qualquer sistema estável não, não apenas M/M/1):

$$L = \lambda W \quad \text{e} \quad L_q = \lambda W_q$$

3.2. Sistema M/M/k

o modelo M/M/k, que é uma extensão natural do M/M/1 para múltiplos servidores paralelos. Esse modelo é amplamente usado em sistemas de computação distribuída, data centers, call centers, redes de telecomunicações, entre outros — sempre que há vários recursos atendendo uma fila única.
Vamos organizar essas fórmulas e premissas de forma clara e prática.
Premissas:

- ✓ Chegadas seguem um processo de Poisson com taxa λ
- ✓ Tempos de serviço são exponenciais com taxa μ
- ✓ k servidores idênticos
- ✓ Fila única, capacidade infinita
- ✓ Ordem de atendimento: FIFO
- ✓ Condição de estabilidade: $\rho = (\lambda/k\mu) < 1$

Teoria das Filas e Aplicação à Simulação de Sistemas Digitais

NEWTON PAIVA wyden

Parâmetros:

Elemento	Descrição
λ	Taxa média de chegada de clientes
μ	Taxa média de serviços por servidor
k	Número de servidores paralelos
ρ	Fator de utilização por servidor: ρ = (λ/kμ)
Condição de estabilidade	ρ < 1 -> o sistemas não entra em colapso

Medidas de Desempenho (Fórmulas Principais):

Métrica	Fórmula	Interpretação
1. Utilização por servidor	$\rho = \frac{\lambda}{k\mu}$	Medo o quanto cada servidor está ocupado
2. Probabilidade de sistema vazio	$P_0 = \left[\sum_{n=0}^{k-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^k}{k!} \cdot \frac{1}{1-\rho}\right]^{-1}$	A probabilidade de que não haja nenhum cliente no sistema — ou seja, nenhum cliente em atendimento e nenhum na fila.
3. Probabilidade de espera (Erlang-c)	$P_{\text{espera}} = \frac{\frac{(A)^k}{k!} \cdot \frac{k}{k-A}}{\sum_{n=0}^{k-1} \frac{A^n}{n!} + \frac{A^k}{k!} \cdot \frac{k}{k-A}}$	Chance ou probabilidade de um cliente ter que esperar na fila
4. Número médio na fila	$L_q = \frac{(\lambda/\mu)^k \cdot \rho}{k! \cdot (1-\rho)^2} \cdot P_0$	Clientes aguardando atendimento
5. Número médio no sistema	$L = L_q + \frac{\lambda}{\mu}$	Clientes na fila + clientes sendo atendidos
6. Tempo médio na fila	$W_q = \frac{L_q}{\lambda}$	Tempo de espera antes do serviço
7. Tempo médio no sistema	$W = W_q + \frac{1}{\mu}$	Tempo total: espera + serviço

Aplicações práticas em computação:

- Servidores de aplicação: múltiplos threads ou instâncias atendendo requisições simultâneas.
- Cloud computing: balanceamento de carga entre máquinas virtuais.
- Sistemas de filas em microserviços: onde múltiplos workers processam tarefas de uma fila comum.
- Call centers virtuais: modelagem de atendimento simultâneo por agentes.

Conclusões:

A Teoria das Filas fornece as ferramentas analíticas para modelar, analisar e prever o comportamento de sistemas de espera.

Os modelos M/M/1 e M/M/k, embora simples, capturam a essência da aleatoriedade nestes sistemas e são a base para modelos mais complexos.

O entendimento da notação de Kendall é crucial para a comunicação e identificação precisa do modelo a ser utilizado.

Em simulação computacional, estes modelos analíticos servem como benchmark para validar e calibrar modelos de simulação mais complexos e realistas que fogem das suposições matemáticas restritivas (como populações finitas ou distribuições não-exponenciais).